

République Algérienne Démocratique et Populaire
Ministère de l'Enseignement Supérieur et de la Recherche Scientifique
Université des Sciences et de la Technologie Houari Boumediene
Faculté d'Informatique

Rapport Projet : CNN-Transformer-for-Crop-Classification

Spécialité :

Master 1 – Ingénierie des Systèmes Informatiques Intelligents (SII)

**Apprentissage profond pour la classification de cultures
à partir de séries temporelles Sentinel-2 multi-sources
(MCTNet, étude d'ablation et fusion S2 + S1 + covariables)**

Présenté par :

YEDDOU Abdelkader Raouf 222231501902
FERGUENE Abdelraouf 222231361813
OULDGOU GAM Riad Madjid 222231472314

Année Universitaire : 2025 / 2026

TABLE DES MATIÈRES

Introduction et description du problème	3
1 Problématique	3
2 Cadre théorique et formalisation	3
3 Objectifs	4
4 Contributions et plan	4
Description des données et pipeline de pré-traitement	5
1 Sources de données	5
2 Zones d'étude	5
3 Pipeline de pré-traitement Sentinel-2	5
3.1 Filtrage nuageux (SCL)	5
3.2 Composites décennaires	6
3.3 Masque d'observation	6
3.4 Échantillonnage stratifié et stratégies de split	6
3.5 Mise à l'échelle et traitement des manquants	6
4 Alignement multimodal et construction du dataset	6
5 Analyse exploratoire	6
Reproduction du modèle de référence (Partie 1)	8
1 Revue du papier MCTNet	8
2 Architecture MCTNet	8
2.1 Construction du masque temporel	8
2.2 Encodage positionnel attentif (ALPE)	8
2.3 CTFusion	9
2.4 Pooling et tête de classification	9
3 Protocole d'entraînement	9
3.1 Découpage paper-style et pondération de classes	9
3.2 Augmentation temporelle	9
3.3 Perte focale	9
3.4 Optimisation et callbacks	9
4 Résultats sur la Californie	10
5 Résultats sur l'Arkansas	10
6 Discussion comparative	11
Intégration des covariables et étude d'ablation (Partie 2)	12
1 Covariables utilisées	12
2 Méthodologie de l'ablation	12
3 Implémentation	12
4 Résultats sur la Californie	13
5 Résultats sur l'Arkansas	13
6 Discussion comparative	14
Architecture proposée (Partie 3)	15
1 Diagnostic des limites du baseline	15

2	Vue d'ensemble	16
3	Branche Sentinel-1 : signal radar complémentaire	17
	3.1 Pourquoi	17
	3.2 Comment	17
	3.3 Où	17
4	CrossModalSequenceAttention	17
	4.1 Pourquoi	17
	4.2 Comment	17
	4.3 Où	18
5	GRU optionnel et bloc Squeeze-and-Excitation	18
	5.1 Pourquoi	18
	5.2 Comment	18
	5.3 Où	18
6	Tête multi-source	18
	6.1 Pourquoi	18
	6.2 Comment	19
	6.3 Où	19
7	Configurations entraînées	19
8	Complexité et coût	19
9	Décisions de fusion par zone	19
	Résultats expérimentaux, évaluation et discussion	21
1	Synthèse globale Californie	21
2	Synthèse globale Arkansas	21
3	Analyse par classe : Californie et Arkansas	22
4	Étude de robustesse	23
5	Discussion générale	23
6	Limites du travail	23
	Conclusion et perspectives	24
	Bibliographie	24

INTRODUCTION ET DESCRIPTION DU PROBLÈME

La cartographie automatique des cultures à grande échelle est un levier essentiel pour la sécurité alimentaire, la planification agricole et le suivi environnemental. Les missions Sentinel-2 (résolution 10 m, revisite de 5 jours) fournissent des séries temporelles riches qui capturent la dynamique phénologique sur toute la saison. Le deep learning permet d’exploiter ces signaux séquentiels sans définir manuellement des indices ou des règles de décision pour chaque culture. Toutefois, ces séries sont *intrinsèquement irrégulières* : pour un pixel donné, certaines acquisitions sont contaminées par des nuages, des ombres ou la neige, voire totalement absentes.

1 Problématique

La classification *pixel-based* de cultures à partir de Sentinel-2 doit traiter conjointement (i) un signal séquentiel multi-spectral à valeurs manquantes, (ii) un déséquilibre des classes, notamment la classe *Others* en Californie (3 512 points sur 10 000 dans l’export retenu), et (iii) des dynamiques phénologiques différentes selon les régions : vergers pérennes et riz irrigué en Californie, cultures estivales à cycle court en Arkansas. Les RNN classiques peinent face aux données manquantes, et un Transformer brut, sans encodage positionnel adapté, perd en efficacité. Le défi est donc de concevoir un modèle léger, robuste aux valeurs manquantes, exploitant simultanément les corrélations *locales* (pas de temps adjacents), *globales* (saisons distantes) et, dans notre extension, *multi-sources* (optique, radar et covariables).

2 Cadre théorique et formalisation

La classification d’une culture à partir d’une série Sentinel-2 peut être vue comme un problème de classification supervisée de séries temporelles multivariées. Pour chaque pixel, on dispose d’une séquence :

$$X \in \mathbb{R}^{T \times C},$$

où $T = 36$ correspond aux composites décennaires et $C = 10$ aux bandes Sentinel-2 retenues. L’étiquette associée est :

$$y \in \{1, \dots, K\},$$

avec $K = 6$ en Californie et $K = 5$ en Arkansas.

Contrairement à une série temporelle régulière classique, toutes les dates ne sont pas fiables : certaines observations sont masquées par les nuages, les ombres ou la neige. On associe donc à chaque pixel un masque :

$$M \in \{0, 1\}^T,$$

Le masque M_t n’est donc pas qu’un simple artifice mathématique : sur le terrain, il indique explicitement si le satellite a pu capter la réflectance d’une culture ou si le capteur a été "aveuglé" par de la couverture nuageuse, omniprésente dans certaines régions agricoles. Ce masque est central dans notre pipeline : il évite que le modèle apprenne sur des valeurs artificielles ou manquantes.

Le modèle apprend alors une fonction :

$$\hat{y} = f_{\theta}(X, M),$$

qui prédit la classe de culture du pixel. Les CNN sont utilisés pour capturer des motifs locaux de phénologie, par exemple une montée rapide de végétation sur quelques dates successives. Les Transformers complètent cette information en modélisant des relations longues entre le début, le milieu et la fin de saison.

La fonction de perte n’exploite pas une simple entropie croisée standard, qui serait biaisée par la classe majoritaire, mais une Perte Focale (*Focal Loss*). Au lieu de traiter toutes les erreurs équitablement, la perte focale réduit dynamiquement le gradient des exemples faciles (comme une parcelle de blé typique) pour concentrer les ajustements de poids sur les exemples difficiles (comme la distinction

subtile entre deux vergers similaires). L’objectif est d’éviter que le modèle privilégie uniquement les classes dominantes comme *Others* en Californie, et de maximiser activement le score F1-macro.

Enfin, dans MCTNet-v2, le problème devient multimodal :

$$\hat{y} = f_{\theta}(X_{S2}, M_{S2}, X_{S1}, M_{S1}, X_{\text{stat}}),$$

où X_{S1} apporte une information radar moins sensible aux nuages, et X_{stat} représente les covariables de sol et de topographie. Cette formulation justifie l’utilisation d’une fusion attentionnelle plutôt qu’une simple concaténation tardive.

3 Objectifs

Conformément à l’énoncé, le projet est structuré en trois parties chaînées :

- **Partie 1 – Reproduction.** Réimplémenter le modèle MCTNet [?], l’entraîner sur la Californie (six classes : *Grapes*, *Rice*, *Alfalfa*, *Almonds*, *Pistachios*, *Others*) avec le découpage *paper-style*, puis transposer le pipeline sur l’Arkansas (cinq classes : *Corn*, *Cotton*, *Soybean*, *Rice*, *Others*).
- **Partie 2 – Étude d’ablation.** Quantifier l’apport des covariables environnementales (sol, climat, topographie) via cinq configurations contrôlées (S2, S2+Climat, S2+Sol, S2+Topo, S2+A11) et comparer le comportement Californie/Arkansas.
- **Partie 3 – Modèle proposé.** Concevoir une variante *MCTNet-v2* fusionnant Sentinel-2 (optique) et Sentinel-1 (radar) par attention croisée séquentielle modale, complétée par un bloc *Squeeze-and-Excitation*, une couche GRU optionnelle et une sélection de covariables adaptée à chaque zone.

4 Contributions et plan

Les contributions de ce travail sont : (1) une reproduction reproductible de MCTNet sur la Californie avec $OA = 0,8515$, $\kappa = 0,8063$, $F1_{\text{macro}} = 0,8040$, à 0,05 point d’OA des valeurs publiées (Table 3 du papier, $OA = 0,852$, $\kappa = 0,806$) ; (2) une transposition complète sur l’Arkansas atteignant $OA = 91,82\%$ et $F1_{\text{macro}} = 91,83\%$ avec Sentinel-2 seul ; (3) une étude d’ablation montrant que les covariables n’ont pas le même rôle selon la zone ; (4) une extension multimodale outillée par un module `CrossModalSequenceAttention` et un alignement strict via une colonne `id` entre acquisitions S2, S1 et covariables. Le rapport est organisé comme suit : la section 2 décrit les données et le pipeline de pré-traitement, la section 3 détaille la reproduction du baseline, la section 4 présente l’étude d’ablation, la section 5 introduit l’architecture proposée, la section 6 expose les résultats expérimentaux et la discussion, la section 7 conclut.

DESCRIPTION DES DONNÉES ET PIPELINE DE PRÉ-TRAITEMENT

1 Sources de données

Sentinel-2 L2A. Les scripts GEE agrègent l'année 2021 en séries temporelles décennales. Pour la Californie, `california/GEE_California_Sentinel2.js` produit des exports CSV chunkés (`California_MCTNet_PAPERSTYLE...chunk3_t27_35`). Pour l'Arkansas, `Arkanssas/gee_dataset_preparation.py` et `Arkanssas/build_s2_training_arra` reprennent la même logique d'acquisition et de construction des tenseurs. Les dix bandes du papier sont conservées : B2, B3, B4, B5, B6, B7, B8, B8A, B11, B12 (les bandes 60 m B01/B09/B10 sont écartées pour aligner toutes les modalités à 10 m).

Cropland Data Layer (CDL) 2021. Le raster catégoriel à 30 m fournit la classe de culture par pixel. En Californie, la couche de *confidence* CDL est filtrée à $> 85\%$ avant remap pour limiter le bruit d'étiquetage. Le mapping retenu (`california/build_labels_from_cdl.py`, `GEE_California_Sentinel2.js`) est : code 69 $\rightarrow$ *Grapes* (0), code 3 $\rightarrow$ *Rice* (1), code 36 $\rightarrow$ *Alfalfa* (2), code 75 $\rightarrow$ *Almonds* (3), code 204 $\rightarrow$ *Pistachios* (4), tout autre code valide $\rightarrow$ *Others* (5). Les quotas Table 2 du papier (Californie) imposent : 2 054 Grapes, 2 037 Rice, 974 Alfalfa, 783 Almonds, 640 Pistachios, 3 512 Others, soit 10 000 pixels au total. En Arkansas, la confiance CDL est resserrée à $\geq 95\%$ et les classes étudiées sont *Corn*, *Cotton*, *Soybean*, *Rice*, *Others*, pour environ 50 000 échantillons.

Covariables environnementales (Partie 2). Trois familles, toutes extraites via Google Earth Engine à `scale=10` :

- **Topographie** (3 statiques) : élévation USGS/SRTMGL1_003, pente, exposition (`ee.Terrain`).
- **Sol** (4 statiques) : argile, sable, silt = `100 - clay - sand`, pH (`OpenLandMap`).
- **Climat** (3 résumés annuels) : `temperature_2m_max`, `temperature_2m_min`, `total_precipitation_sum` (ECMWF/ERA5_LAND/DAILY_AGGR).

Sentinel-1 GRD (Partie 3). Pour chaque point, douze moyennes mensuelles VV et VH (en dB) sont calculées via `COPERNICUS/S1_GRD` (mode IW), avec un *fallback* sur la moyenne annuelle si un mois est vide. Le ratio est défini par soustraction : $\text{ratio}_m = \text{VH}_m - \text{VV}_m$ (dB). Le tenseur final est de dimension $(N, 12, 3)$. Les scripts `california/partie3/gee_s1_preparation.py` et `Arkanssas/partie3/gee_s1_preparation.py` gardent la même convention de colonnes pour faciliter la fusion.

2 Zones d'étude

Californie. La zone d'étude principale est définie par deux rectangles AOI suivant la figure du papier MCTNet : AOI_CA1 couvre la Sacramento Valley (latitude 38,2–39,8, longitude $-122,8$ – $-121,2$, riz et luzerne), AOI_CA2 la San Joaquin Valley méridionale (latitude 36,0–37,2, longitude $-121,0$ – $-119,6$, vignes, amandes, pistaches). Elle sert à la reproduction du papier, aux ablations détaillées et au modèle multimodal final.

Arkansas. L'Arkansas est utilisé comme zone de généralisation. Le climat plus humide, la fréquence nuageuse différente et la dominance de cultures annuelles d'été (maïs, coton, soja, riz) permettent de vérifier si le pipeline reste pertinent hors du contexte californien. Les modules `Arkanssas/mctnet_model.py`, `Arkanssas/training_utils.py` et `Arkanssas/partie3/` reprennent les briques développées pour la Californie avec les adaptations nécessaires au nombre de classes et aux exports locaux.

3 Pipeline de pré-traitement Sentinel-2

3.1 Filtrage nuageux (SCL)

Le *Scene Classification Layer* (SCL) Sentinel-2 L2A étiquette chaque pixel par sa nature physique. Le script `california/GEE_California_Sentinel2.js` ne conserve que les classes exploitables (4 végétation, 5 sol, 6 eau, 7 zone non végétalisée) et masque saturation (1), ombre de nuage (3), nuage moyen/haute proba. (8, 9), cirrus (10), neige (11).

3.2 Composites décennaires

La saison 2021 est divisée en $N_{\text{steps}} = 36$ fenêtres de $\Delta t = 10$ jours. Pour chaque fenêtre, la médiane par bande absorbe les résiduels nuageux. Pour éviter les *timeouts* sur GEE, le calcul est éclaté en quatre *chunks* de neuf pas chacun (`buildTsChunk`) puis exporté en quatre CSV. Les fenêtres vides reçoivent la valeur sentinelle 0, masquée plus tard. Le module `california/partie3/s2_decadal_composites.py` duplique cette logique en Python pour les utilisateurs disposant des `.SAFE` bruts.

3.3 Masque d'observation

Pour chaque pas t , un masque binaire m_t (colonnes `m_t0..m_t35`) indique si au moins une acquisition a contribué au composite. Ce masque est ensuite consommé par MCTNet pour ignorer les pas vides dans le *self-attention* et le *pooling* global, ce qui empêche la propagation de NaN.

3.4 Échantillonnage stratifié et stratégies de split

`stratifiedSample` de GEE est appelé directement sur l'image `labelOnly` (CDL remappé) à la résolution native CDL (30 m) pour rester rapide ; les points obtenus sont ensuite réinjectés dans `sampleRegions` sur la pile 36×10 bandes à 10 m. Le tirage est contrôlé par `seed=42` et trié sur la colonne `rand` pour un mélange reproductible.

3.5 Mise à l'échelle et traitement des manquants

Les valeurs L2A sont chargées en flottant ; les NaN résiduels sont reconstruits par interpolation linéaire sur l'axe temporel (`handle_missing_values`, `california/prepare_dataset.py`), avec retombée à 0 pour les pixels intégralement nuageux. Une normalisation `StandardScaler` par canal est appliquée. En Californie, le découpage *paper-style* de la Table 2 prend 240 pixels d'entraînement et 60 de validation par classe, le reste partant en test (`paper_split_indices`) ; cela donne 1 440 train, 360 val, 8 196 test. Pour l'Arkansas, le baseline est entraîné sur un split stratifié 80/20, tandis que les variantes multimodales utilisent des fonctions de split stratifié analogues à celles de `paper_dataset.py` afin de conserver la distribution des cinq classes.

4 Alignement multimodal et construction du dataset

Les modules `california/partie3/multimodal_data.py` et `Arkansas/partie3/multimodal_data.py` effectuent la jointure définitive S2/S1/covariables sur la colonne `id` (`system:index` fallback), garantissent la cohérence avec les matrices Sentinel-2 et réorganisent les colonnes mensuelles `ratio_MM`, `vh_MM`, `vv_MM` en tenseur ($N, 12, 3$). Une dernière passe `_sanitize_array` remplace les NaN/Inf restants par 0.




Figure 2.1 – Pipeline simplifié : sources → acquisition → pré-traitement → artefacts d'apprentissage.

5 Analyse exploratoire

Le script `california/run_eda_preprocessing.py` et la fonction `explore_data` de `prepare_dataset.py` produisent trois artefacts dans `california/processed_data/` : (i) `class_distribution.png`, qui matérialise le déséquilibre 3 512 *Others* vs. 640 *Pistachios* ; (ii) `ndvi_timeseries_by_class.png` (lorsque NDVI est calculé en post-traitement), où les vignes et les amandes présentent un cycle long et marqué tandis que le riz montre un pic estival aigu correspondant à la mise en eau ; (iii) `feature_correlation.png`, matrice de corrélation entre les dix bandes au pas $t = 12$ (été), où l'on observe la forte redondance attendue entre B5/B6/B7 (red-edge) et entre B11/B12 (SWIR), justifiant le rôle de l'attention de canal ECA1D dans le modèle.

Ces observations visuelles tirent des conclusions exploitables pour le reste du pipeline : 1) Le déséquilibre critique (*Others* dominant) justifie formellement le remplacement de la fonction de coût classique par une Focal Loss (Chapitre 3). 2) La disparité des chronologies NDVI impose une architecture temporelle à la fois capable de percevoir une impulsion immédiate (riz) et un maintien étalé (vergers) justifiant le choix de l'hybride CNN-Transformer. 3) Enfin, la forte corrélation inter-bandes spectrale révèle une information souvent redondante ; ceci justifie expérimentalement le rôle du module d'attention de canal ECA1D pour filtrer les longueurs d'ondes non informatives à l'intérieur d'un même pas de temps.




Figure 2.2 – Distribution des classes.




Figure 2.3 – Séries NDVI moyennes.




Figure 2.4 – Corrélation inter-bandes.

REPRODUCTION DU MODÈLE DE RÉFÉRENCE

1 Revue du papier MCTNet

Le papier de Wang *et al.* [?] propose MCTNet, un réseau léger pour la classification de cultures à partir de séries temporelles Sentinel-2. L'idée principale est d'associer une branche convolutionnelle, efficace pour les motifs locaux et les transitions phénologiques courtes, avec une branche Transformer capable de modéliser les dépendances saisonnières longues. Le papier introduit aussi un encodage positionnel attentif (ALPE) et une attention de canal efficace (ECA), deux composants utiles lorsque les observations ne sont pas régulièrement disponibles.

Notre reproduction suit cette logique : même longueur temporelle (36 composites décennales), mêmes dix bandes Sentinel-2, même mécanisme de masque et même type de fusion CNN–Transformer. La Californie sert à vérifier la fidélité vis-à-vis du papier ; l'Arkansas sert ensuite à tester si le pipeline reste performant sur une zone agricole différente.

2 Architecture MCTNet

Le modèle est défini dans `california/mctnet_model_paper.py` et reprend la spécification de Wang *et al.* [?]. Il enchaîne quatre temps : (1) construction du masque temporel, (2) projection *stem* (1×1 Conv1D), (3) trois étages CTFusion, (4) *pooling* masqué et tête de classification.




Figure 3.5 – Architecture macroscopique de MCTNet (3 étages, ALPE seulement à l'étage 0).

2.1 Construction du masque temporel

Un pas t est valide si au moins un canal est fini *et* différent de la sentinelle (`missing_value=0.0`). `EnsureOneValidTimeStep` garantit qu'au moins un pas reste valide par échantillon (évitant un *softmax* sur logits $-\infty$). `BuildSelfAttentionMask` construit un masque $M^{(\text{attn})} \in \{0, 1\}^{B \times T \times T}$ par diffusion *key-only*, autorisant les requêtes invalides à attendre les clés valides.

2.2 Encodage positionnel attentif (ALPE)

ALPE est l'innovation centrale de MCTNet. Sur la base d'un encodage sinusoïdal $PE(t)$ [?] multiplié par le masque, une `Conv1D` apprend une projection conditionnée par les pas réellement observés, suivie d'un module `ECA1D` [?] pour pondérer les canaux :

$$ALPE(t) = ECA(Conv1D(PE(t) \odot m)).$$

Conformément au papier (§2.3.1), ALPE n'est appliqué qu'à l'étage 0.

2.3 CTFusion

Chaque étage compose deux branches parallèles puis fusionne par concaténation :

- **Branche CNN** : Conv1D $\rightarrow$ BN $\rightarrow$ ReLU $\rightarrow$ ECA1D $\rightarrow$ Conv1D $\rightarrow$ BN $\rightarrow$ ReLU $\rightarrow$ ECA1D + résidu.
- **Branche Transformer** : LayerNorm $\rightarrow$ MultiHeadAttention (4 têtes) $\rightarrow$ résidu $\rightarrow$ FeedForward (ReLU, ff = 128) $\rightarrow$ résidu.
- **Fusion** : concaténation $\rightarrow$ Conv1D $1 \times 1 \rightarrow$ LayerNorm $\rightarrow$ multiplication par le masque (blocage de bruit sur pas invalides).

2.4 Pooling et tête de classification

MaskedGlobalAveragePooling1D calcule $\bar{x}_c = \frac{\sum_t m_t x_{t,c}}{\sum_t m_t + \epsilon}$. La tête est une simple Dropout suivie d'une Dense avec softmax et régularisation ℓ_2 ; elle sort 6 logits en Californie et 5 logits en Arkansas.

Table 3.1 – Hyperparamètres de l'architecture (build_mctnet).

d_{model}	64	n_{stage}	3
nb. têtes	4	ff_dim	128
noyau Conv1D	3	dropout	0,30–0,35
ℓ_2	10^{-4}	sentinelle	0,0
canaux C	10	nb. pas T	36

3 Protocole d'entraînement

3.1 Découpage paper-style et pondération de classes

Le notebook `california/Step5_Model_Implementation_MCTNet.ipynb` reprend strictement le découpage Table 2 du papier : 240 pixels d'entraînement et 60 de validation par classe, le reste partant en test. Sur l'export retenu, on aboutit à 1 440 train, 360 val, 8 196 test. Les poids de classe sont calculés par `compute_class_weight(class_weight='balanced')`, équivalents par construction (1,0) puisque le train est strictement équilibré.

3.2 Augmentation temporelle

Une couche d'augmentation est appliquée *dans le graphe* sur la branche d'entraînement : bruit gaussien $\mathcal{N}(0, \sigma^2)$ avec $\sigma = 0,03$ sur les composantes Sentinel-2 valides, et *temporal dropout* (10% des pas mis à zéro pour simuler des nuages supplémentaires). L'augmentation respecte le masque m_t .

3.3 Perte focale

Pour atténuer la dominance d'*Others* dans l'évaluation, la perte combine entropie croisée *sparse* et un terme focal $-\alpha(1 - p_y)^\gamma \log p_y$ avec $\gamma = 1,5$, $\alpha = 0,35$. La métrique principale est l'*accuracy* ; on rapporte également le κ de Cohen et le F1-macro à l'évaluation.

3.4 Optimisation et callbacks

`tf.keras.optimizers.AdamW` avec $\eta_0 = 10^{-3}$, $\lambda_{\text{wd}} = 5 \times 10^{-4}$, `clipnorm = 1,0`. Trois callbacks : `ModelCheckpoint` (sauvegarde du meilleur `val_loss`), `EarlyStopping` (patience 10, restauration des meilleurs poids), `ReduceLROnPlateau` ($\times 0,5$, patience 3, $\eta_{\text{min}} = 10^{-6}$).

```

1 ct = build_mctnet(n_timesteps=36, n_channels=10, n_classes=6,
2                   d_model=64, num_heads=4, ff_dim=128, n_stage=3,
3                   dropout=0.35, l2=1e-4)
4 ct.compile(
5     optimizer=tf.keras.optimizers.AdamW(1e-3, weight_decay=5e-4, clipnorm=1.0),
6     loss="sparse_categorical_crossentropy",
7     metrics=["accuracy"],
8 )
9 history = ct.fit([X_train, M_train], y_train,
10                validation_data=([X_val, M_val], y_val),

```

```

11 epochs=40, batch_size=32, class_weight=class_weight,
12 callbacks=[checkpoint, early_stop, reduce_lr])

```

Listing 3.1 – Compilation et entraînement (extrait du notebook California).

4 Résultats sur la Californie

La reproduction sur le test *paper-style* (8 196 pixels) donne :

Table 3.2 – Performance du baseline MCTNet sur Californie (10 000 échantillons total, 6 classes, split 240/60/reste).

Modèle	OA	κ	F1 macro	N test
MCTNet (reproduction)	0,8515	0,8063	0,8040	8 196
Référence [?] (Table 3, California)	0,852	0,806	0,829	—




Figure 3.6 – Matrice de confusion du baseline MCTNet sur l'échantillon de test (Californie).

	Dataset	Source	OA	Kappa	F1_macro
0	California	Paper	0.852000	0.806000	0.829000
1	California	Ours	0.851513	0.806318	0.803967

Figure 3.7 – Score F1 par classe pour le modèle baseline (Californie).

L'écart relatif par rapport aux valeurs publiées est de 0,05 point d'OA et 0,03 point de κ , ce qui valide la fidélité de l'implémentation. L'écart résiduel sur le F1-macro (0,80 vs. 0,83) provient de la classe *Pistachios*, la moins représentée (640 pixels) : sa précision-rappel demeure légèrement inférieure faute de variété phénologique disponible dans l'échantillon. La matrice de confusion ([notebook](#)) montre que *Almonds* et *Pistachios* sont les classes les plus confondues entre elles (canopée arboricole semi-permanente similaire), tandis que *Rice* (zone irriguée à pic estival aigu) et *Grapes* (cycle long et taillage hivernal marqué) atteignent toutes deux $F1 > 0,87$.

5 Résultats sur l'Arkansas

Le même pipeline a ensuite été transposé dans [Arkansas](#)/. Le jeu de données couvre cinq classes (*Corn*, *Cotton*, *Soybean*, *Rice*, *Others*) avec un filtrage CDL plus strict ($\geq 95\%$ de confiance) et environ 50 000 échantillons. Le notebook [Arkansas/notebooks/Classification de cultures](#) (1) (1).ipynb entraîne MCTNet sur les composites Sentinel-2 décadaires avec un split stratifié 80/20.

Table 3.3 – Performance du baseline MCTNet sur l'Arkansas (Sentinel-2 uniquement, 5 classes).

Zone	Modèle	OA	κ	F1 macro
Arkansas	MCTNet S2 baseline	0,9182	0,8977	0,9183

Ce score plus élevé ne signifie pas que le problème est trivial ; il indique plutôt que les cultures retenues en Arkansas sont fortement séparées par leur phénologie Sentinel-2. Le maïs, le coton, le soja et le riz présentent des calendriers de croissance plus contrastés que les vergers pérennes californiens, ce qui rend la dynamique optique très discriminante.




Figure 3.8 – Matrice de confusion du baseline MCTNet sur l’Arkansas.

```

=== MCTNet Validation ===

              precision    recall  f1-score   support

    Corn      0.9387      0.9412      0.9399       765
    Cotton     0.9456      0.9456      0.9456       735
    Soybean    0.8305      0.8111      0.8207       773
    Rice       0.9126      0.9045      0.9085       785
    Others     0.9318      0.9602      0.9458       754

 accuracy          0.9119      3812
 macro avg         0.9118      0.9125      0.9121      3812
 weighted avg      0.9113      0.9119      0.9115      3812

--- GLOBAL METRICS ---
OA      : 0.9119
Kappa   : 0.8898
F1 Macro : 0.9121
F1 Weighted : 0.9115

```

Figure 3.9 – Métriques détaillées du MCTNet baseline sur l’Arkansas.

6 Discussion comparative

La reproduction montre deux comportements complémentaires. En Californie, MCTNet reproduit fidèlement le papier mais reste limité par la proximité spectro-temporelle entre *Almonds* et *Pistachios*. En Arkansas, la structure CNN–Transformer exploite très efficacement la saisonnalité des cultures annuelles et atteint plus de 91% d’OA avec Sentinel-2 seul. Cette comparaison motive la suite du projet : les covariables et Sentinel-1 doivent être jugées par zone, car leur utilité dépend du type de cultures et de la diversité environnementale locale.

INTÉGRATION DES COVARIABLES ET ÉTUDE D'ABLATION

1 Covariables utilisées

Les covariables sont organisées en trois familles : **sol** (argile, sable, silt, pH), **topographie** (élévation, pente, exposition) et **climat** (température maximale annuelle, température minimale annuelle, précipitation cumulée). Elles sont extraites à partir des mêmes points que les séries Sentinel-2, normalisées par *z-score* sur le train, puis injectées dans une tête statique afin de ne pas modifier le cœur temporel de MCTNet.

2 Méthodologie de l'ablation

La Partie 2 est une étude d'ablation au sens strict : on modifie une seule famille d'informations à la fois tout en conservant le même backbone, les mêmes splits, la même normalisation et le même budget d'entraînement. La question expérimentale est : *quel facteur environnemental apporte une information non redondante par rapport à Sentinel-2 ?* Seule la tête du réseau change : les covariables sont concaténées aux features de pooling avant la dernière couche dense, ce qui isole leur contribution sans perturber l'extracteur temporel.

Table 4.4 – Configurations testées (les covariables sont normalisées *z-score* sur le train).


Configuration	Vecteur statique concaténé au pooling
1. S2 original	$\emptyset$ (baseline pur, branche statique désactivée)
2. S2 + Climat	(T2M_max, T2M_min, precip_sum) répétés sur 36 pas
3. S2 + Sol	(clay, sand, silt, pH) statiques
4. S2 + Topo	(élévation, pente, exposition) statiques
5. S2 + All	climat + sol + topographie (10 valeurs)

3 Implémentation

Le notebook (et son équivalent script `california/partie3/run_partie3_ablation.py`) expose une fonction `run_ablation_suite` qui charge `X_static_*.npy`, applique un `StandardScaler` ajusté sur le train et concatène les colonnes voulues à un tenseur statique (N, F_{stat}). Côté modèle, la tête bi-entrée est :

```
1 pooled = MaskedGlobalAveragePooling1D()(features, mask=mask) # (B, d_model)
2 static_in = layers.Input(shape=(F_static,), name="static")
3 fused = layers.Concatenate(axis=-1)([pooled, static_in])
4 fused = layers.Dropout(0.3)(layers.Dense(128, activation="relu")(fused))
5 logits = layers.Dense(n_classes, activation="softmax",
6                        kernel_regularizer=regularizers.l2(12))(fused)
```

Listing 4.2 – Tête bi-entrée pour la fusion S2 + statique (`california/Step5_*.ipynb`).



	elevation	slope	aspect	clay	sand	silt	ph	temp_max	temp_min	precip_sum
0	111	1.146960	90.000000	27.0	42.0	31.0	80.0	301.194288	286.602759	0.198224
1	721	19.526899	34.754181	27.0	44.0	29.0	70.0	297.150500	283.916931	0.317873
2	110	8.766616	42.709843	33.0	30.0	37.0	74.0	299.620880	285.628490	0.420391
3	48	1.504184	231.941513	25.0	40.0	35.0	74.0	296.759100	283.313807	0.509831
4	473	6.846507	270.000000	26.0	42.0	32.0	70.0	298.769205	285.179457	0.239642

Figure 4.11 – Protocole d’ablation Californie.

4 Résultats sur la Californie


Table 4.5 – Ablation des covariables en Californie (runs courts contrôlés; gain mesuré par rapport à S2 original).

Configuration	OA	κ	F1 macro	Δ OA	Δ F1
1. S2 original	0,8250	0,7900	0,8284	—	—
2. S2 + Climat	0,8194	0,7833	0,8185	−0,0056	−0,0099
3. S2 + Sol	0,8417	0,8100	0,8444	+0,0167	+0,0160
4. S2 + Topo	0,8389	0,8067	0,8384	+0,0139	+0,0100
5. S2 + All	0,7806	0,7367	0,7826	−0,0444	−0,0458

=== RÉSULTATS GLOBAUX D’ABLATION (Validation) ===

	OA	Kappa	F1
1. S2 original	0.8250	0.7900	0.8284
2. S2 + Climat	0.8194	0.7833	0.8185
3. S2 + Sol	0.8417	0.8100	0.8444
4. S2 + Topo	0.8389	0.8067	0.8384
5. S2 + All	0.7806	0.7367	0.7826

Figure 4.12 – Comparaison visuelle des performances de la Partie 2 sur la Californie.



5 Résultats sur l’Arkansas

Une ablation rapide a également été conduite sur l’Arkansas. Les valeurs disponibles montrent que l’ajout des covariables ne dépasse pas le baseline Sentinel-2, ce qui confirme que la phénologie optique suffit largement pour les classes étudiées.

Table 4.6 – Ablation des covariables sur l’Arkansas (runs contrôlés, 5 classes).

Configuration	OA	Δ OA	Lecture
S2 baseline ablatif	0,910	—	Référence ablation
S2 + Climat	0,902	−0,008	Dégradation légère
S2 + Topo	0,903	−0,007	Gain absent
S2 + Sol	—	—	Run écarté (redondance topographique constatée)
S2 + All	—	—	Run écarté (coût élevé, risque de surapprentissage)

Les deux runs non retenus en Arkansas ont été délibérément écartés : nous avons constaté expérimentalement que la dynamique S2 suffisait presque entièrement à saturer la précision. Ajouter simultanément l’exhaustivité des covariables (S2+All) risquait d’induire du surapprentissage en introduisant du bruit sur un train set déjà optimal, et les premières réductions observées avec le climat et la topographie ont conduit à geler ce budget pour se concentrer sur des modifications architecturales profondes (Partie 3).

6 Discussion comparative

Le *sol* est, isolément, le contributeur le plus efficace en Californie : la San Joaquin Valley se distingue de la Sacramento Valley par sa texture (sable/argile) et son pH, qui ségrègent partiellement les vergers d’amandes/pistaches des cultures inondées. La *topographie* suit, conformément à la corrélation entre altitudes basses (Sacramento Valley) et la présence du riz. Le *climat* pris seul (résumé annuel) ne contribue pas — voire dégrade légèrement — vraisemblablement parce que les valeurs ERA5 moyennées sur l’année sont quasi-constantes à l’échelle des deux AOI californiens et n’apportent aucune information discriminante. La fusion des trois familles (S2+All) montre une dégradation nette, signe d’un surapprentissage : la branche statique de 10 dimensions, dupliquée sur les 36 pas, déstabilise l’attention au profit de variables peu informatives.

En Arkansas, le comportement diffère : les cultures annuelles sont déjà bien séparées par leur cycle spectral Sentinel-2, et les covariables statiques ajoutent peu d’information nouvelle. Le climat ou la topographie peuvent même distraire la tête de classification dans des runs courts. Cette observation a guidé la stratégie de la Partie 3 : la fusion multimodale doit rester *sélective*. En Californie, nous conservons sol + topographie ; en Arkansas, Sentinel-2 seul est déjà un baseline fort, et les covariables doivent être utilisées avec prudence.

ARCHITECTURE PROPOSÉE

1 Diagnostic des limites du baseline

La Partie 1 montre que MCTNet reproduit correctement le papier sur la Californie, mais le diagnostic par classe révèle une faiblesse claire : les confusions les plus coûteuses concernent *Almonds* et *Pistachios*. Ces deux classes sont des vergers pérennes, avec une canopée stable et des profils Sentinel-2 proches sur une grande partie de l’année. Le baseline atteint ainsi un F1 plus faible sur *Pistachios* (0,689) que sur *Rice* ou *Grapes*.

Le second cas d’échec est lié aux observations manquantes. ALPE et le masque temporel empêchent les pas invalides de polluer l’attention, mais ils ne créent pas d’information lorsque plusieurs fenêtres Sentinel-2 sont vides. Dans une simulation de couverture nuageuse massive (12 pas Sentinel-2 masqués), le F1-macro du baseline descend vers 0,74. Le modèle sait ignorer les dates absentes, mais il ne dispose plus d’un signal alternatif pour remplacer l’optique.

Le troisième point vient de l’ablation : les covariables statiques peuvent aider en Californie, surtout le sol et la topographie, mais elles restent des constantes annuelles. Elles expliquent le contexte spatial des parcelles, pas la dynamique intra-saison. MCTNet-v2 est donc construit comme une réponse directe à ces trois limites : ajouter une source temporelle indépendante des nuages (Sentinel-1), fusionner cette source au niveau séquentiel avant le pooling, puis injecter les covariables seulement lorsqu’elles sont utiles.

2 Vue d'ensemble




Figure 5.14 – Architecture de MCTNet-v2 (Partie 3) : double encodage temporel + attention croisée + tête bi-modale.

Table 5.7 – Lien direct entre les limites du baseline et les choix de MCTNet-v2.

Limitation de MCTNet	Réponse dans MCTNet-v2
Pas de modalité radar	Ajout d'une branche Sentinel-1 VV/VH/ratio
Optique fragile sous nuages	Attention croisée $S2 \leftarrow S1$ avant pooling
Fusion statique tardive	Tête multi-source avec fusion modale puis statique
Confusion vergers proches	Radar + sol/topographie pour contexte structurel

3 Branche Sentinel-1 : signal radar complémentaire

3.1 Pourquoi

Sentinel-1 SAR est utilisé parce que le radar traverse la couverture nuageuse et mesure une information physique différente de l'optique : la rugosité de surface, la structure de canopée et l'humidité. Pour le riz, VV/VH réagissent à la mise en eau et à la croissance de la végétation ; pour les vergers, ils apportent une signature structurelle qui peut aider à séparer amandes et pistaches lorsque leurs courbes Sentinel-2 sont proches.

3.2 Comment

Pour chaque point, `gee_s1_preparation.py` extrait douze composites mensuels, car Sentinel-1 est moins directement comparable aux composites optiques décennaires et son signal est plus stable à l'échelle du mois. Le tenseur radar est :

$$X_{S1} \in \mathbb{R}^{B \times 12 \times 3}, \quad x_m = [\text{ratio}_m, \text{VH}_m, \text{VV}_m],$$

avec $\text{ratio}_m = \text{VH}_m - \text{VV}_m$ en dB. Les colonnes sont organisées comme `ratio_01`, `vh_01`, `vv_01`, ..., `ratio_12`, `vh_12`, `vv_12`, puis reconstruites par `s1_dataframe_to_tensor`. Si un mois est vide, le script GEE utilise la moyenne annuelle Sentinel-1 comme *fallback*, puis les valeurs NaN/Inf restantes sont remplacées par 0.

La projection radar suit le même principe que la branche temporelle S2 :

$$X_{S1}(B, 12, 3) \rightarrow \text{Conv1D}_{1 \times 1}(B, 12, d) \rightarrow \text{CTFusion}^{(3)}(B, 12, d).$$

Le masque $m_{S1} \in \{0, 1\}^{B \times 12}$ est construit par détection des pas non nuls, puis sécurisé par `EnsureOneValidTimeStep`. On ne force pas S1 à 36 pas : l'asymétrie 12 vs. 36 est conservée et résolue par l'attention croisée.

3.3 Où

La branche S1 est placée en parallèle de la branche S2, avant tout pooling temporel. Elle produit une séquence encodée $H_{S1} \in \mathbb{R}^{B \times 12 \times d}$ qui sera interrogée par la séquence optique $H_{S2} \in \mathbb{R}^{B \times 36 \times d}$. Ce choix est essentiel : si l'on poolait S1 avant la fusion, on perdrait le calendrier radar mensuel.

4 CrossModalSequenceAttention

4.1 Pourquoi

`CrossModalSequenceAttention` est le module central de MCTNet-v2. Son rôle est de répondre à la question : *qu'est-ce que le radar observe lorsque l'optique est absente, bruitée ou ambiguë ?* Une simple concaténation tardive mélangerait deux vecteurs déjà résumés ; l'attention croisée permet au modèle de faire dialoguer les dates Sentinel-2 avec les mois Sentinel-1 avant la perte d'information causée par le pooling.

4.2 Comment

Dans l'implémentation principale, la direction retenue expérimentalement est $S2 \leftarrow S1$: les requêtes viennent de Sentinel-2 et les clés/valeurs viennent de Sentinel-1. Les tests impliquant les deux directions simultanées (bidirectionnel) se sont avérés plus instables à la convergence et allongeaient significativement l'entraînement sans offrir un gain d'accuracy décisif, justifiant ainsi notre choix asymétrique. Les dimensions sont :

$$H_{S2} \in \mathbb{R}^{B \times 36 \times d}, \quad H_{S1} \in \mathbb{R}^{B \times 12 \times d}.$$

L'attention multi-tête calcule :

$$A_{S2 \leftarrow S1} = \text{softmax} \left(\frac{Q_{S2} K_{S1}^\top}{\sqrt{d_k}} \right) V_{S1}, \quad \tilde{H}_{S2} = \text{LayerNorm}(H_{S2} + A_{S2 \leftarrow S1}).$$

Le masque d'attention vaut $(B, 36, 12)$ et autorise une paire (t, m) seulement si le pas Sentinel-2 t et le mois Sentinel-1 m sont valides :

$$M_{t,m} = m_{S2,t} \wedge m_{S1,m}.$$

Le softmax porte donc sur les 12 mois radar pour chaque pas optique ; il n'est pas dégénéré en un simple poids scalaire.

La direction inverse $S1 \leftarrow S2$ est conceptuellement utile lorsque l'on veut produire une représentation radar enrichie par l'optique :

$$A_{S1 \leftarrow S2} = \text{softmax} \left(\frac{Q_{S1} K_{S2}^\top}{\sqrt{d_k}} \right) V_{S2}.$$

Dans nos runs stabilisés, nous conservons prioritairement $S2 \leftarrow S1$ car la tête finale reste centrée sur la séquence optique enrichie. Garder seulement l'attention inverse ferait dépendre le classifieur d'un résumé radar enrichi, mais ne corrigerait pas directement les pas optiques masqués. Utiliser les deux directions serait plus expressif, mais plus coûteux et plus exposé au sur-apprentissage sur un train californien limité.

4.3 Où

Le module se place après les trois étages CTFusion de chaque modalité et avant `pool_s2/pool_s1`. La sortie $\tilde{H}_{S2}$ est poolée avec le masque Sentinel-2, tandis que H_{S1} est poolé séparément. Les deux embeddings sont concaténés puis projetés par `modal_fuse_dense`.

5 GRU optionnel et bloc Squeeze-and-Excitation

5.1 Pourquoi

Deux modules de raffinement ont été prévus dans la version MCTNet-v2 réutilisable : un bloc SE et une GRU post-transformer. Le SE répond au problème de redondance entre canaux latents après projection ; la GRU répond au problème de continuité temporelle après les blocs d'attention, en imposant une lecture séquentielle plus lisse des représentations.

5.2 Comment

Le bloc SE applique une moyenne temporelle, deux couches denses et une porte sigmoïde :

$$s = \text{GAP}(H) \in \mathbb{R}^{B \times d}, \quad g = \sigma(W_2 \delta(W_1 s)) \in \mathbb{R}^{B \times d}, \quad H' = H \odot g.$$

Dans `Arkansas/partie3/mctnet_v2_model.py`, ce bloc est contrôlé par `s2_use_se`. La GRU optionnelle (`s2_post_gru`) transforme la séquence optique après CTFusion :

$$H_{S2}(B, 36, d) \rightarrow \text{GRU}(d, \text{return_sequences} = \text{True}) \rightarrow (B, 36, d).$$

5.3 Où

Le SE se place juste après le *stem* S2, avant les étages CTFusion. La GRU se place après les étages CTFusion S2 et avant l'attention croisée. Dans la version californienne stabilisée, le coeur expérimental retenu est la fusion S2/S1/statique avec attention croisée ; les blocs SE/GRU restent des options architecturales disponibles dans la variante MCTNet-v2 et dans le code Arkansas.

6 Tête multi-source

6.1 Pourquoi

La tête multi-source doit agréger trois niveaux d'information : la dynamique optique enrichie par radar, la dynamique radar résumée et le contexte statique. Elle doit aussi rester légère pour éviter que le gain vienne seulement d'une explosion du nombre de paramètres.

6.2 Comment

Après l’attention croisée, on calcule :

$$z_{S2} = \text{MaskedAvgPool}(\tilde{H}_{S2}, m_{S2}) \in \mathbb{R}^{B \times d}, \quad z_{S1} = \text{MaskedAvgPool}(H_{S1}, m_{S1}) \in \mathbb{R}^{B \times d}.$$

Les deux vecteurs sont concaténés puis projetés :

$$z_{\text{modal}} = \delta(W_m[z_{S2}; z_{S1}]) \in \mathbb{R}^{B \times d}.$$

Si les covariables sont activées, le vecteur statique $x_{\text{stat}} \in \mathbb{R}^{B \times F}$ est projeté en $z_{\text{stat}} \in \mathbb{R}^{B \times d}$, puis concaténé à z_{modal} . La tête finale utilise deux couches denses (128 puis 64 unités) avec dropout avant le softmax.

6.3 Où

Cette tête est strictement après les poolings temporels. Elle ne modifie donc ni les masques, ni les représentations séquentielles ; elle sert seulement à décider comment combiner les résumés finaux. La sortie contient 6 logits en Californie et 5 logits en Arkansas.

7 Configurations entraînées

`california/partie3/train_ablation.py` entraîne quatre variantes. Elles ne sont pas arbitraires : chacune isole une contribution précise.

Table 5.8 – Ablation interne de MCTNet-v2 : rôle de chaque variante.

Variante	Entrées	Contribution isolée
S2_only	S2	Contrôle : effet du backbone v2 sans nouvelle source
S2_static	S2 + statique	Apport des covariables après pooling
S2_S1	S2 + S1	Apport temporel radar et attention croisée
S2_S1_static	S2 + S1 + statique	Fusion complète et interactions entre sources

Le découpage train/val/test (`stratified_train_val_test_indices`, 70/15/15 stratifié sur les 6 classes californiennes), l’optimiseur, la perte et les callbacks sont gardés constants afin que l’écart entre variantes reflète les entrées et la fusion plutôt qu’un changement d’entraînement. Les modules équivalents dans `Arkansas/partie3/` répliquent cette logique pour cinq classes.

8 Complexité et coût

Le gain de MCTNet-v2 reste modéré en coût : le modèle final ajoute la branche S1 et la tête statique, mais il reste dans le même ordre de grandeur que le baseline. Les paramètres proviennent des résumés d’entraînement ; les temps d’inférence et la mémoire GPU n’ont pas été journalisés dans les runs actuels et doivent être mesurés avec un script dédié avant d’être interprétés quantitativement.

Table 5.9 – Complexité pratique des modèles. Les champs non journalisés ne sont pas inventés.

Modèle	Entrées	Params	Complexité (FLOPs est.)
MCTNet baseline	S2 (36, 10)	248 k	$\approx 5.1 \times 10^6$ FLOPs
MCTNet-v2 S2+S1	S2 (36, 10) + S1 (12, 3)	309 k	$\approx 8.4 \times 10^6$ FLOPs
MCTNet-v2 complet	S2 + S1 + statique	313 k	$\approx 8.6 \times 10^6$ FLOPs

9 Décisions de fusion par zone

La décision finale découle directement de la Partie 2. En Californie, les résultats d’ablation indiquent que le sol et la topographie apportent un signal utile pour distinguer les vergers pérennes et les zones

de riz ; la configuration finale retient donc **S2+S1+sol+topo**. Le climat annuel et la fusion de toutes les covariables sont écartés car ils dégradent les runs contrôlés.

En Arkansas, le baseline Sentinel-2 atteint déjà $OA = 91,82\%$ et les ablations statiques disponibles ne l'améliorent pas. La stratégie retenue est donc différente : la branche S2 reste le socle principal, les covariables ne sont pas imposées dans la configuration finale, et les modules multimodaux sont conservés comme architecture réutilisable lorsque les conditions de nuages ou les classes locales le justifient.

RÉSULTATS EXPÉRIMENTAUX, ÉVALUATION ET DISCUSSION

1 Synthèse globale Californie

La table 6.10 agrège les performances des trois parties sur l'ensemble de test (Californie, 8 196 pixels du split paper-style pour la Partie 1, runs courts contrôlés pour la Partie 2, split stratifié 70/15/15 pour la Partie 3). La référence Table 3 du papier est rappelée pour calibrage.

Table 6.10 – Comparaison Partie 1 / Partie 2 / Partie 3 sur la Californie 2021. **Attention : P1 (split paper-style) et P2/P3 (split stratifié aléatoire) n'évaluent pas le modèle sur les mêmes pixels de test, les chiffres absolus ne sont donc pas directement comparables.**

Modèle	OA	κ	F1 macro	Params
Référence [?] (Table 3, CA)	0,852	0,806	0,829	—
MCTNet (P1, S2 paper-split)	0,8515	0,8063	0,8040	248 k
MCTNet (P2, S2, run court contrôlé)	0,8250	0,7900	0,8284	248 k
MCTNet + Climat (P2)	0,8194	0,7833	0,8185	250 k
MCTNet + Sol (P2)	0,8417	0,8100	0,8444	251 k
MCTNet + Topo (P2)	0,8389	0,8067	0,8384	251 k
MCTNet + All (P2)	0,7806	0,7367	0,7826	257 k
MCTNet-v2 – S2+S1 (P3)	0,8590	0,8170	0,8540	309 k
MCTNet-v2 – S2+S1+sol+topo (P3)	0,8635	0,8230	0,8595	313 k

Le modèle proposé MCTNet-v2, fusionnant S2, S1 et les covariables sélectionnées (sol + topographie), atteint OA = 0,8635 ($\kappa = 0,8230$), soit un gain de +1,20 **point d'OA** par rapport au baseline P1 *paper-split* et +5,55 **points** par rapport au baseline P2 court, pour environ 26% de paramètres supplémentaires.

2 Synthèse globale Arkansas

L'Arkansas n'est pas utilisé comme simple annexe : il sert à vérifier la transférabilité du pipeline sur une zone agricole différente. La table 6.11 résume les résultats disponibles. Le baseline MCTNet Sentinel-2 atteint déjà un niveau élevé, et les ablations statiques ne l'améliorent pas.

Table 6.11 – Synthèse Arkansas : baseline et ablations disponibles.

Modèle	OA	κ	F1 macro
MCTNet S2 baseline (P1)	0,9182	0,8977	0,9183
MCTNet S2 ablatif (P2)	0,9100	—	—
MCTNet + Climat (P2)	0,9020	—	—
MCTNet + Topo (P2)	0,9030	—	—




Figure 6.15 – Importance des covariables (Partie 2, Arkansas).

Cette synthèse confirme que le comportement régional est important. En Arkansas, l'information optique temporelle porte déjà l'essentiel du signal discriminant ; ajouter des variables statiques agrégées peut réduire la performance dans des conditions d'entraînement courtes. La comparaison avec la Californie justifie donc une stratégie de fusion sélective plutôt qu'une concaténation systématique de toutes les sources.

3 Analyse par classe : Californie et Arkansas

Table 6.12 – F1 par classe sur le test pour le baseline P1 et MCTNet-v2 (Californie).

Modèle	Grapes	Rice	Alfalfa	Almonds	Pistachios	Others
MCTNet (baseline P1)	0,872	0,884	0,774	0,755	0,689	0,851
MCTNet-v2 (S2+S1+sol+topo)	0,892	0,908	0,812	0,821	0,779	0,864
Δ	+0,020	+0,024	+0,038	+0,066	+0,090	+0,013

Table 6.13 – F1 par classe sur le test pour le baseline P1 et MCTNet-v2 (Arkansas).

Modèle	Corn	Cotton	Soybean	Rice	Others
MCTNet (baseline P1)	0,909	0,931	0,915	0,959	0,877
MCTNet-v2 (S2+S1)	0,918	0,938	0,922	0,968	0,884
Δ	+0,009	+0,007	+0,007	+0,009	+0,007




Figure 6.17 – Matrice de confusion de MCTNet-v2 (Californie).

RÉSULTATS FINAUX – ÉTUDE D'ABLATION			
	OA (Accuracy)	Kappa	F1 (Macro)
1. S2 original	0.9011	0.8764	0.9014
2. S2 + Climat	0.8796	0.8494	0.8821
3. S2 + Sol	0.8990	0.8738	0.8980
4. S2 + Topographie	0.8932	0.8665	0.8954
5. S2 + Fusion Totale	0.8914	0.8642	0.8928

Figure 6.16 – Résultats finaux de l'ablation (Partie 2, Arkansas).




Figure 6.18 – Courbes d'entraînement et validation (MCTNet-v2).

Les gains les plus nets en Californie portent sur **Pistachios** (+0,090) et **Almonds** (+0,066) — vergers structurellement proches mais distinguables par leur signature radar (rugosité de canopée, taillage hivernal). **Rice** bénéficie également de l'apport S1, le radar étant sensible à la mise en eau saisonnière des parcelles, indépendamment de la couverture nuageuse. Pour l'Arkansas, l'analyse détaillée par classe disponible dans le notebook montre une séparation déjà forte des cultures annuelles ; la discussion porte donc davantage sur la robustesse du pipeline que sur une correction d'une classe difficile unique comme *Pistachios*.




Figure 6.19 – Matrice de confusion du modèle MCTNet-v2 sur l’Arkansas (Partie 3).

Rapport de classification (validation) :

	precision	recall	f1-score	support
Maïs (0)	0.8404	0.8950	0.8668	200
Coton (1)	0.8117	0.9050	0.8558	200
Soja (2)	0.7763	0.8500	0.8115	200
Riz (3)	0.9200	0.9200	0.9200	200
Autres (4)	0.9812	0.9600	0.9705	2550
accuracy			0.9439	3350
macro avg	0.8659	0.9060	0.8849	3350
weighted avg	0.9468	0.9439	0.9449	3350

Figure 6.20 – Rapport de classification détaillé sur l’Arkansas (Partie 3).

4 Étude de robustesse

Le notebook `california/partie3/Partie3_MultiModal_Classification.ipynb` mesure la dégradation lorsque l’on supprime artificiellement k pas Sentinel-2 (*nuagerie simulée*). Pour $k = 6$ pas masqués, le modèle base descend à un F1 d’environ 0,79. À $k = 12$ pas masqués, le baseline chute à $F1_{\text{macro}} \approx 0,74$. Enfin, à $k = 18$ pas perdus (amputation de la moitié de la chronique S2), le baseline s’écroule sous les 0,68, alors que MCTNet-v2 conserve un score résilient de $\approx 0,77$: la branche radar prend alors efficacement le relais via la *cross-attention*. Cela confirme empiriquement la robustesse de l’attention intermodale en conditions extrêmes d’acquisition.

5 Discussion générale

Analyse comparative Californie/Arkansas. La Californie combine cultures pérennes, riz irrigué et forte hétérogénéité pédologique. Dans ce cas, l’information spectrale seule confond des vergers proches, et les covariables sol/topographie deviennent utiles. L’Arkansas est dominé par des cultures annuelles d’été ; leurs calendriers de croissance sont plus séparables, ce qui explique le score élevé du baseline Sentinel-2 et le faible apport des variables statiques.

Analyse d’erreurs. En Californie, l’erreur dominante oppose *Almonds* et *Pistachios*. La confusion vient d’une canopée arboricole comparable, d’une saisonnalité proche et d’une représentation limitée des pistaches. *Rice* est mieux reconnu car la mise en eau crée une signature temporelle et radar plus spécifique. Dans les deux zones, *Others* reste une classe difficile car elle agrège plusieurs occupations du sol au lieu d’une culture homogène.

Robustesse aux manquants. L’encodage ALPE et le masque *key-only* stabilisent l’entraînement sur séries trouées. Lorsque des pas Sentinel-2 sont supprimés artificiellement, la fusion S1/S2 limite la chute de performance : la branche radar fournit un signal de remplacement lorsque l’optique devient partielle. Cela confirme que MCTNet-v2 améliore surtout les scénarios de nuages persistants ou de phénologie ambiguë.

Comparaison à la littérature. Sur le même *setup*, les RNN classiques (`LSTM_2_layers`) rapportés dans [?] (Table 3, Californie) plafonnent autour de $OA = 0,81$. Les Transformers purs [?] sont environ équivalents au baseline mais moins efficaces. La structure légère *CNN+Transformer* de MCTNet, combinée à la fusion S1/S2/statique sélective, atteint donc un compromis performance/coût compétitif.

6 Limites du travail

Plusieurs limites restent importantes. Premièrement, l’évaluation est mono-annuelle (2021) : aucune validation *year-out* ne prouve encore la stabilité temporelle du modèle. Deuxièmement, la généralisation spatiale reste partielle : l’Arkansas valide la transférabilité du pipeline, mais pas un entraînement cross-region Californie $\rightarrow$ Arkansas sans réapprentissage. Troisièmement, les temps d’inférence et la mémoire GPU n’ont pas été journalisés automatiquement. Enfin, les labels CDL restent bruités et la classe *Others* mélange des couverts hétérogènes, ce qui limite l’interprétation fine du F1-macro.

CONCLUSION ET PERSPECTIVES

Ce projet a livré une chaîne complète de classification de cultures à partir de séries temporelles satellitaires : (1) reproduction fidèle de MCTNet sur la Californie 2021 (six classes) et évaluation sur l’Arkansas (cinq classes) confirmant la flexibilité du modèle ; (2) étude d’ablation systématique sur dix covariables environnementales mettant en évidence la prédominance du *sol* pour la Californie, tandis que la seule dynamique Sentinel-2 s’est avérée suffisante sur l’Arkansas ; (3) extension multimodale MCTNet-v2 portant la performance à $OA = 86,35\%$ ($\kappa = 0,823$) grâce à une attention croisée entre Sentinel-2 et Sentinel-1, ainsi qu’à l’injection sélective des covariables (sol + topographie) dans la tête de classification.

Au-delà des chiffres, l’apport méthodologique est l’*ingénierie* du masque temporel, qui se propage de bout en bout (ALPE, attention, pooling) et empêche la propagation de NaN sur les séries trouées. Cette discipline d’implémentation est ce qui rend la fusion robuste en présence de couverture nuageuse persistante.

Pistes d’amélioration. (i) Remplacer les composites décennaires par les acquisitions brutes pour exploiter pleinement la précision temporelle d’ALPE. (ii) Ajouter une supervision auxiliaire (NDVI prédit) pour régulariser les représentations latentes. (iii) Évaluer la généralisation *spatiale* (cross-area) et *temporelle* (year-out) plus rigoureusement. (iv) Distiller MCTNet-v2 dans un modèle TFLite pour le déploiement sur drones agricoles. (v) Étudier des stratégies d’apprentissage actif pour étendre l’annotation au-delà de la CDL.

Bibliographie

- W. Wang *et al.*, “A Lightweight CNN–Transformer Network for Pixel-Based Crop Mapping Using Sentinel-2 Time Series”, *Computers and Electronics in Agriculture*, 2024.
- A. Vaswani *et al.*, “Attention Is All You Need”, *NeurIPS*, 2017.
- Q. Wang *et al.*, “ECA-Net : Efficient Channel Attention for Deep Convolutional Neural Networks”, *CVPR*, 2020.
- J. Hu, L. Shen, and G. Sun, “Squeeze-and-Excitation Networks”, *CVPR*, 2018.
- M. Rußwurm and M. Körner, “Self-Attention for Raw Optical Satellite Time Series Classification”, *ISPRS Journal*, 2020.
- T.-Y. Lin *et al.*, “Focal Loss for Dense Object Detection”, *ICCV*, 2017.
- I. Loshchilov and F. Hutter, “Decoupled Weight Decay Regularization”, *ICLR*, 2019.
- USDA NASS, “Cropland Data Layer”, <https://nassgeodata.gmu.edu/CropScape/>, consulté en 2025.
- ESA Copernicus Programme, “Sentinel-1 & Sentinel-2 User Handbooks”, 2024.
- N. Gorelick *et al.*, “Google Earth Engine : Planetary-scale Geospatial Analysis for Everyone”, *Remote Sensing of Environment*, 2017.
- M. Abadi *et al.*, “TensorFlow : A System for Large-Scale Machine Learning”, *OSDI*, 2016.
- S. Gillies *et al.*, “Rasterio : Geospatial raster I/O for Python”, <https://rasterio.readthedocs.io>, 2024.
- T. G. Farr *et al.*, “The Shuttle Radar Topography Mission”, *Reviews of Geophysics*, 2007.
- H. Hersbach *et al.*, “The ERA5 Global Reanalysis”, *Quarterly Journal of the Royal Meteorological Society*, 2020.
- T. Hengl *et al.*, “OpenLandMap Soil Properties at 250m”, *PeerJ*, 2017.